

PRODUCT REQUIREMENTS DOCUMENT

AEGIS — Nền tảng kiểm thử độ bền vững cho mô hình Perception

Tên đầy đủ: Adversarial Evaluation & Guard for Intelligent Perception Systems

Phiên bản PRD: 1.0

Trạng thái: Draft for MVP

Loại sản phẩm: Web-based AI Robustness Testing Platform

Đối tượng triển khai: Hackathon/MVP, sau đó mở rộng thành nền tảng kiểm thử nội bộ

Tagline: Kiểm định độ bền vững AI — trước khi thực tế kiểm định bạn.

PHẦN I — PRODUCT REQUIREMENTS DOCUMENT

1. Tổng quan sản phẩm

AEGIS là nền tảng hỗ trợ đội ngũ phát triển mô hình perception kiểm tra khả năng hoạt động của mô hình trong các điều kiện bất lợi như:

- Nhiễu ảnh và lỗi cảm biến.
- Sương mù, mưa, tuyết, thay đổi ánh sáng.
- Vật thể bị che khuất.
- Camera hoặc LiDAR bị mất dữ liệu.
- Adversarial digital attack.
- Adversarial patch.
- Black-box và transfer attack.

Hệ thống cho phép người dùng chọn dữ liệu, model và nhóm tấn công; tự động tạo các biến thể kiểm thử; chạy suy luận; đo mức suy giảm; trực quan hóa lỗi; và chuyển các trường hợp nguy hiểm sang Reviewer để đưa ra quyết định cuối cùng.

AEGIS chỉ phục vụ mục đích mô phỏng và kiểm thử. Hệ thống không đưa model trực tiếp lên môi trường vận hành thực tế.

2. Bối cảnh và vấn đề cần giải quyết

Các mô hình perception thường đạt kết quả tốt trên dữ liệu sạch nhưng có thể suy giảm mạnh khi gặp điều kiện thực tế như thời tiết xấu, nhiễu cảm biến hoặc tấn công có chủ đích.

Quy trình kiểm thử hiện tại thường gặp các vấn đề:

Vấn đề	Hệ quả
Các phép kiểm thử nằm trong nhiều script rời rạc	Khó lặp lại và khó so sánh

Vấn đề	Hệ quả
Không chuẩn hóa mức độ tấn công	Kết quả giữa các model thiếu nhất quán
Tổng hợp kết quả thủ công	Tốn thời gian, dễ sai
Không kiểm soát chi phí GPU	Dễ vượt ngân sách khi quét nhiều tổ hợp
Không truy ngược từ chỉ số về ảnh lỗi	Khó tìm nguyên nhân model thất bại
Thiếu bước phê duyệt của con người	Có nguy cơ hiểu nhầm kết quả mô phỏng
Dữ liệu có mặt và biến số chưa được xử lý	Có nguy cơ vi phạm quyền riêng tư

AEGIS giải quyết các vấn đề trên bằng một quy trình thống nhất:

Dataset → Anonymization → Attack Generation → Model Inference → Evaluation → Review → Report

3. Tầm nhìn sản phẩm

AEGIS đóng vai trò như một hệ thống “crash test” hoặc “penetration test” dành cho mô hình perception.

Thay vì chờ mô hình thất bại trong môi trường thực tế, đội kỹ sư chủ động tạo ra các điều kiện bất lợi trong môi trường mô phỏng để:

1. Phát hiện điểm yếu của model.
2. Định lượng mức suy giảm.
3. Xác định loại tấn công nguy hiểm nhất.
4. Tìm các trường hợp cần bổ sung dữ liệu hoặc retrain.
5. So sánh độ bền vững giữa các phiên bản model.
6. Cung cấp bằng chứng cho quyết định của Reviewer.

4. Mục tiêu sản phẩm

4.1 Mục tiêu chính

- Cho phép tạo và chạy một Test Run từ giao diện web.
- Hỗ trợ kiểm thử model trên dữ liệu sạch và dữ liệu bị biến đổi.
- Tính các chỉ số mAP, IoU, Degradation, Robustness Accuracy và Attack Success Rate.
- Hiển thị trực quan sự khác biệt trước và sau tấn công.
- Tự động tổng hợp Robustness Matrix theo loại tấn công và mức độ.
- Phát hiện các biến thể làm model suy giảm mạnh nhất.
- Kiểm soát ngân sách GPU trước và trong khi chạy.
- Bảo đảm dữ liệu được ẩn danh trước khi kiểm thử.
- Bắt buộc có con người phê duyệt các kết quả quan trọng.

4.2 Mục tiêu MVP

MVP phải chứng minh được luồng đầu-cuối:

1. Upload hoặc import dataset.
2. Thực hiện anonymization.
3. Chọn model YOLO hoặc SAM2.
4. Chọn corruption, PGD hoặc adversarial patch.
5. Chạy Test Run.
6. Theo dõi tiến trình.
7. Xem ảnh trước và sau tấn công.
8. Xem bảng suy giảm mAP hoặc IoU.
9. Gắn cờ trường hợp lỗi.
10. Reviewer đưa ra quyết định.

4.3 Ngoài phạm vi MVP

Các nội dung sau chưa bắt buộc trong phiên bản đầu:

- Kết nối trực tiếp với production deployment.
- Tự động phê duyệt model để triển khai.
- Digital Twin hoặc CARLA đầy đủ.
- Đánh giá end-to-end hành vi điều khiển xe.
- Hỗ trợ toàn bộ model M1-M6.
- Toàn bộ nhóm tấn công A-F.
- Hệ thống thanh toán hoặc định giá GPU thực tế.
- Huấn luyện lại model trực tiếp trên AEGIS.

5. Nguyên tắc sản phẩm

5.1 Safety-first

Kết quả của AEGIS không được hiểu là chứng nhận triển khai thực tế.

Mọi màn hình phải có banner:

SIMULATION ONLY — Kết quả chưa được validate cho triển khai thực tế.

5.2 Human-in-the-loop

Hệ thống có thể:

- Tính điểm.
- Phát hiện bất thường.
- Gắn cờ tự động.
- Đề xuất mức độ rủi ro.

Hệ thống không được tự đưa ra quyết định triển khai model.

5.3 Privacy by design

Dataset chưa có manifest ẩn danh không được phép sử dụng để tạo Test Run.

5.4 Cost-aware

Người dùng phải nhìn thấy ước tính tài nguyên trước khi chạy.

5.5 Traceability

Mọi chỉ số phải truy ngược được về:

- Dataset.
- Phiên bản model.
- Loại tấn công.
- Mức độ tấn công.
- Ảnh hoặc frame cụ thể.
- Người tạo Test Run.
- Reviewer và quyết định review.

5.6 Model-agnostic

Model được tích hợp thông qua `ModelAdapter`. Việc thêm model mới không yêu cầu sửa lỗi hệ thống.

6. Đối tượng người dùng

6.1 Engineer

Mục tiêu

- Tạo Test Run.
- Tìm điểm yếu của model.
- Xem ảnh lỗi.
- So sánh model.
- Gửi trường hợp cần đánh giá cho Reviewer.

Quyền chính

- Tạo và quản lý dataset.
- Khởi chạy anonymization.
- Tạo, tạm dừng hoặc hủy Test Run.
- Xem báo cáo.
- Gắn cờ case.
- Thêm ghi chú kỹ thuật.

6.2 Reviewer

Mục tiêu

- Đánh giá mức độ nghiêm trọng.
- Kiểm tra bằng chứng.
- Đưa ra quyết định cuối cùng.
- Lưu dấu vết phê duyệt.

Quyền chính

- Xem toàn bộ report và case được gửi review.
- Xem lịch sử model.
- Yêu cầu chạy lại.
- Ghi quyết định.
- Xem audit log.

6.3 Admin

Đây là vai trò mở rộng.

Quyền chính

- Quản lý người dùng và phân quyền.
- Quản lý Model Registry.
- Thiết lập ngân sách GPU.
- Thiết lập ngưỡng Robustness Gate.
- Xem mức sử dụng tài nguyên theo nhóm.

7. Phạm vi chức năng

7.1 Nhóm P0 — Bắt buộc cho MVP

ID	Chức năng
P0-01	Đăng nhập và phân quyền Engineer/Reviewer
P0-02	Upload hoặc import dataset
P0-03	Anonymization mặt và biến số
P0-04	Khóa dataset chưa ẩn danh
P0-05	Đăng ký và chọn model
P0-06	Chọn nhóm tấn công và severity
P0-07	Ước tính GPU trước khi chạy
P0-08	Tạo và theo dõi Test Run
P0-09	So sánh ảnh trước/sau

ID	Chức năng
P0-10	Tính mAP/IoU trước và sau
P0-11	Tính Degradation
P0-12	Robustness Matrix cơ bản
P0-13	Gắn cờ case cần review
P0-14	Reviewer đưa ra quyết định
P0-15	Audit log
P0-16	Export CSV hoặc PDF cơ bản

7.2 Nhóm P1 — Nâng cao

ID	Chức năng
P1-01	Severity Sweep tự động
P1-02	Robustness Accuracy theo severity
P1-03	Attack Success Rate
P1-04	Robustness Score 0-100
P1-05	Benchmark nhiều model
P1-06	Worst-Case Top-N
P1-07	Cache kết quả
P1-08	Dynamic batching
P1-09	Active Sampling
P1-10	Đồng bộ W&B
P1-11	So sánh model version
P1-12	Báo cáo chi phí GPU

7.3 Nhóm P2 — Đột phá

ID	Chức năng
P2-01	Auto Red-Team Search
P2-02	Explainable Failure Clustering
P2-03	Grad-CAM overlay
P2-04	CI/CD Robustness Gate
P2-05	Transfer Attack Matrix
P2-06	Digital-Twin Scenario Replay

ID	Chức năng
P2-07	3D perception và multi-sensor fusion

8. User stories

8.1 Dataset và anonymization

US-DATA-01

Là Engineer, tôi muốn upload dataset để sử dụng cho các Test Run.

Điều kiện chấp nhận

- Hệ thống hỗ trợ upload ảnh hoặc import cấu trúc KITTI/nuScenes.
 - Hiển thị số file hợp lệ và không hợp lệ.
 - Dataset được tạo với trạng thái **Pending Anonymization**.
 - Dataset chưa ẩn danh không xuất hiện như một lựa chọn hợp lệ trong New Test Run.
-

US-DATA-02

Là Engineer, tôi muốn xem preview trước và sau anonymization để xác nhận mặt và biển số đã được xử lý.

Điều kiện chấp nhận

- Hiển thị ảnh gốc và ảnh đã blur/mosaic.
 - Hiển thị bounding box vùng bị ẩn danh.
 - Cho phép xem một tập ảnh mẫu.
 - Lưu manifest, trạng thái và thời điểm xử lý.
 - Không có chức năng bỏ qua anonymization đối với dataset bắt buộc xử lý.
-

8.2 Tạo Test Run

US-RUN-01

Là Engineer, tôi muốn chọn dataset, model và nhóm tấn công để tạo Test Run.

Điều kiện chấp nhận

- Chỉ chọn được dataset có trạng thái **Ready**.
 - Chỉ chọn được model có adapter hợp lệ.
 - Có thể chọn một hoặc nhiều nhóm tấn công.
 - Có thể chọn severity cụ thể hoặc Auto Sweep.
 - Hệ thống hiển thị số lượng biến thể dự kiến.
-

US-RUN-02

Là Engineer, tôi muốn biết chi phí GPU dự kiến trước khi chạy.

Điều kiện chấp nhận

- Hiển thị số ảnh, số cấu hình, số inference dự kiến và GPU-hours dự kiến.
 - Cảnh báo khi vượt ngân sách.
 - Không cho phép chạy nếu vượt hard cap.
 - Có thể giảm dataset, severity hoặc nhóm tấn công để giảm chi phí.
-

8.3 Theo dõi tiến trình

US-MON-01

Là Engineer, tôi muốn theo dõi Test Run theo thời gian thực.

Điều kiện chấp nhận

- Hiển thị phần trăm hoàn thành.
 - Hiển thị số biến thể đã chạy trên tổng số.
 - Hiển thị trạng thái từng giai đoạn.
 - Hiển thị GPU utilization.
 - Có nút Cancel.
 - Khi job lỗi, hiển thị nguyên nhân và giai đoạn xảy ra lỗi.
-

8.4 Xem kết quả

US-VIEW-01

Là Engineer, tôi muốn so sánh kết quả model trên ảnh sạch và ảnh bị tấn công.

Điều kiện chấp nhận

- Có chế độ slider hoặc side-by-side.
 - Hiển thị bounding box hoặc mask.
 - Màu xanh thể hiện đối tượng vẫn đúng.
 - Màu đỏ thể hiện đối tượng bị miss hoặc sai class.
 - Màu vàng thể hiện confidence giảm đáng kể.
 - Hiển thị confidence và IoU theo từng object.
-

US-REPORT-01

Là Reviewer, tôi muốn xem Robustness Matrix để xác định loại tấn công nguy hiểm nhất.

Điều kiện chấp nhận

- Hàng thể hiện loại tấn công.
 - Cột thể hiện severity.
 - Ô thể hiện phần trăm suy giảm.
 - Click vào ô mở danh sách ảnh tương ứng.
 - Có thể lọc theo model, class và dataset.
 - Có thể export báo cáo.
-

8.5 Review

US-REV-01

Là Engineer, tôi muốn gửi một case bất thường cho Reviewer.

Điều kiện chấp nhận

- Case phải lưu ảnh gốc, ảnh tấn công, prediction và metric.
 - Engineer có thể ghi chú.
 - Case xuất hiện trong Review Queue.
 - Reviewer được thông báo trong hệ thống.
-

US-REV-02

Là Reviewer, tôi muốn đưa ra quyết định có lưu vết.

Các quyết định hợp lệ

- Chấp nhận rủi ro.
- Yêu cầu retrain.
- Cần thêm dữ liệu.
- Từ chối.

Điều kiện chấp nhận

- Bắt buộc chọn một quyết định.
 - Bắt buộc nhập ghi chú.
 - Lưu người thực hiện và thời gian.
 - Không cho phép sửa trực tiếp bản ghi audit.
 - Khi cần thay đổi quyết định, phải tạo phiên bản quyết định mới.
-

9. Yêu cầu chức năng chi tiết

9.1 Authentication và RBAC

Mã	Yêu cầu	Ưu tiên
AUTH-01	Người dùng đăng nhập bằng email/password hoặc SSO	P0
AUTH-02	Phân quyền Engineer, Reviewer và Admin	P0
AUTH-03	Chặn thao tác không thuộc quyền	P0
AUTH-04	Ghi log đăng nhập và hành động quan trọng	P1

9.2 Dataset Management

Mã	Yêu cầu	Ưu tiên
DATA-01	Upload ảnh, video hoặc point cloud	P0
DATA-02	Import cấu trúc KITTI/nuScenes	P0
DATA-03	Hiển thị metadata và thống kê class	P0
DATA-04	Gắn tag đô thị, cao tốc, ban đêm, thời tiết	P1
DATA-05	Quản lý phiên bản dataset	P1
DATA-06	Kiểm tra file lỗi hoặc thiếu annotation	P0

Trạng thái dataset

```
graph TD
    A[Uploading] --> B[Validating]
    B --> C[Pending Anonymization]
    C --> D[Anonymizing]
    D --> E[Needs Review / Ready / Failed]
```

9.3 Anonymization

Mã	Yêu cầu	Ưu tiên
ANON-01	Phát hiện khuôn mặt	P0
ANON-02	Phát hiện biển số	P0

Mã	Yêu cầu	Ưu tiên
ANON-03	Blur hoặc mosaic vùng phát hiện	P0
ANON-04	Hiển thị preview trước/sau	P0
ANON-05	Lưu manifest và hash	P0
ANON-06	Đo riêng mức giảm AP do anonymization	P1
ANON-07	Không có đường bypass	P0

9.4 Model Registry

Mã	Yêu cầu	Ưu tiên
MODEL-01	Đăng ký model và checkpoint	P0
MODEL-02	Lưu model version	P0
MODEL-03	Kiểm tra adapter	P0
MODEL-04	Hiển thị task: detection, segmentation hoặc 3D	P0
MODEL-05	Lưu metadata framework và input format	P1
MODEL-06	So sánh lịch sử nhiều phiên bản	P1

9.5 Attack Catalog

Mỗi attack plugin phải có:

```

name
input_modality
description
params_schema
severity_levels
cost_class
supported_models
implementation_version

```

Các nhóm attack

Nhóm	Nội dung
A	Common corruption
B	Thời tiết vật lý, depth-aware
C	Che khuất và lỗi cảm biến

Nhóm	Nội dung
D	White-box adversarial
E	Adversarial patch
F	Black-box và transfer

MVP ưu tiên:

- Common corruption.
- Random Erasing hoặc CutOut.
- PGD.
- Một loại adversarial patch.

9.6 Test Run Builder

Wizard gồm bốn bước:

1. Chọn dataset và model.
2. Chọn tấn công.
3. Cấu hình tài nguyên và chế độ chạy.
4. Kiểm tra và xác nhận.

Thông tin bắt buộc:

- Tên Test Run.
- Dataset.
- Model version.
- Attack group.
- Attack method.
- Severity hoặc tham số.
- Sampling mode.
- GPU budget.
- Người tạo.

9.7 Job Orchestration

Trạng thái Test Run

```

Draft
↓
Queued
↓
Preparing
↓
Generating Attacks
↓

```

Running Inference
↓
Evaluating
↓
Completed

Các trạng thái ngoại lệ:

Paused
Cancelled
Failed
Budget Exceeded

Hệ thống phải cho phép người dùng xem giai đoạn hiện tại và thông báo lỗi có thể hành động được.

9.8 Evaluation Engine

Các chỉ số bắt buộc:

Chỉ số	Mục đích
AP_clean	Hiệu năng model trên dữ liệu sạch
AP_attack	Hiệu năng sau biến đổi
IoU/mIoU	Độ chính xác vị trí hoặc mask
Degradation	Phần trăm suy giảm
Robustness Accuracy	Tỷ lệ giữ hiệu năng theo severity
Attack Success Rate	Tỷ lệ tấn công thành công
Robustness Score	Điểm tổng hợp 0-100

Quy tắc hiển thị

- Giá trị gốc và giá trị sau attack phải hiển thị cạnh nhau.
- Mỗi chỉ số phải có tooltip giải thích.
- Không chỉ hiển thị Robustness Score mà không có chỉ số thành phần.
- Click chỉ số phải truy ngược được về ảnh hoặc tập ảnh liên quan.

9.9 Comparison Viewer

Các chế độ hiển thị:

- Slider trước/sau.
- Side-by-side.

- Ảnh tấn công riêng.
- Detection overlay.
- Mask overlay.
- Grad-CAM overlay khi được hỗ trợ.

Panel thông tin gồm:

- Loại attack.
 - Severity.
 - Tham số.
 - Prediction sạch.
 - Prediction sau attack.
 - Confidence trước/sau.
 - IoU trước/sau.
 - Trạng thái object.
-

9.10 Robustness Report

Report phải có:

- Thông tin dataset.
 - Model và version.
 - Phạm vi attack.
 - AP_clean.
 - AP_attack.
 - Degradation.
 - Robustness Matrix.
 - Robustness Accuracy theo severity.
 - Attack Success Rate.
 - Robustness Score.
 - Worst-Case Top-N.
 - GPU-hours.
 - Case chờ review.
 - Quyết định Reviewer, nếu có.
-

9.11 Auto Red-Team Search

Auto Red-Team Search là tính năng P2.

Đầu vào:

- Không gian attack.
- Khoảng severity.
- Epsilon.
- Kích thước patch.
- Vị trí patch.
- Số trial tối đa.
- GPU budget.

Mục tiêu tối ưu:

- Tối thiểu hóa AP hoặc IoU.
- Tối đa hóa ASR.
- Tuân thủ ngân sách GPU.

Đầu ra:

- Tổ hợp tham số nguy hiểm nhất.
- Lịch sử trial.
- Điểm tốt nhất theo thời gian.
- GPU-hours đã sử dụng.
- So sánh với grid search.

9.12 Review Queue

Các nguồn tạo case:

- Engineer gắn cờ thủ công.
- Robustness Score thấp hơn ngưỡng.
- Degradation vượt ngưỡng.
- ASR vượt ngưỡng.
- Case thuộc Worst-Case Top-N.
- CI/CD Gate thất bại.

Reviewer có thể:

- Xem chi tiết.
- Ghi chú.
- Yêu cầu chạy lại.
- Đưa ra quyết định.
- Xem các case tương tự.
- Xem lịch sử quyết định.

10. Yêu cầu phi chức năng

10.1 Bảo mật

- Thực hiện RBAC ở API và giao diện.
- Không chỉ ẩn nút ở frontend.
- Tài nguyên dataset phải có quyền truy cập theo project.
- Checkpoint model không được tải xuống bởi người không có quyền.
- Audit log không được chỉnh sửa trực tiếp.

10.2 Quyền riêng tư

- Dataset chưa ẩn danh bị khóa.
- Ảnh gốc chỉ hiển thị cho vai trò có quyền.
- Manifest anonymization phải được lưu.

- Hệ thống phải chỉ rõ dataset nào đã được blur sẵn.

10.3 Hiệu năng

Mục tiêu MVP đề xuất:

Hoạt động	Mục tiêu
Tải Dashboard	Dưới 3 giây với dữ liệu thông thường
Mở Comparison Viewer	Dưới 2 giây khi artifact đã cache
Cập nhật Job Monitor	Độ trễ dưới 3 giây
Lọc Robustness Matrix	Dưới 2 giây
Cancel job	Phản hồi trạng thái dưới 5 giây

10.4 Khả năng mở rộng

- Attack được phát triển dưới dạng plugin.
- Model được phát triển thông qua adapter.
- Metric có registry riêng.
- Storage sử dụng S3-compatible.
- Queue cho phép bổ sung worker GPU.

10.5 Khả năng quan sát

Hệ thống phải ghi nhận:

- Job state.
- Worker ID.
- GPU utilization.
- GPU memory.
- Số ảnh/giây.
- Cache hit rate.
- Lỗi attack.
- Lỗi inference.
- Lỗi evaluation.
- Chi phí GPU theo run.

10.6 Độ tin cậy

- Job lỗi không được làm mất kết quả đã hoàn thành.
- Có thể chạy lại từ bước bị lỗi khi phù hợp.
- Các phép tính metric phải có version.
- Kết quả phải lưu model version và attack implementation version.

11. Mô hình dữ liệu cấp cao

Các thực thể chính

```
User
Role
Project
Dataset
DatasetVersion
AnonymizationManifest
Model
ModelVersion
ModelAdapter
Attack
AttackConfiguration
TestRun
TestRunJob
Prediction
MetricResult
FailureCase
ReviewDecision
AuditLog
GPUUsage
ExportReport
```

Quan hệ chính

```
Project
├── Dataset
│   ├── DatasetVersion
│   │   └── AnonymizationManifest
│   └── Model
│       ├── ModelVersion
│       └── TestRun
│           ├── AttackConfiguration
│           ├── TestRunJob
│           ├── Prediction
│           ├── MetricResult
│           ├── FailureCase
│           │   └── ReviewDecision
│           └── GPUUsage
```

12. KPI sản phẩm

12.1 KPI về model robustness

KPI	Mô tả
Degradation	Mức suy giảm sau attack
Robustness Accuracy	Khả năng giữ hiệu năng theo severity
Attack Success Rate	Tỷ lệ đối tượng hoặc ảnh bị đánh gục
Robustness Score	Điểm tổng hợp
Worst-case AP/IoU	Điểm thấp nhất tìm được
Số failure pattern	Số nhóm lỗi được phát hiện

12.2 KPI vận hành

KPI	Mục tiêu
Thời gian tạo Test Run	Dưới 5 phút thao tác
Time-to-weakness	Thời gian tìm được case nguy hiểm đầu tiên
Cache hit rate	Tăng dần theo số Test Run
GPU-hours/Test Run	Giảm qua từng phiên bản
Tỷ lệ job thất bại	Dưới 5% ở điều kiện chuẩn
Tỷ lệ case cần review	Theo dõi để tránh Reviewer quá tải
Thời gian xử lý review	Đo từ lúc tạo case đến khi có quyết định

12.3 KPI Auto Red-Team

Mục tiêu dài hạn:

- Tìm được cấu hình có AP thấp tương đương grid search, chênh lệch không quá 1 điểm AP.
- Giảm ít nhất 5 lần GPU-hours so với grid search toàn bộ.

13. Rủi ro sản phẩm

Rủi ro	Biện pháp
Người dùng hiểu Robustness Score là chứng nhận triển khai	Banner Simulation Only và nội dung cảnh báo trong report
Dataset chưa được ẩn danh	Privacy Gate bắt buộc
Attack triển khai sai	Sanity check và version hóa

Rủi ro	Biện pháp
Reviewer quá tải	Failure clustering và ngưỡng gắn cờ
GPU vượt ngân sách	Ước tính, hard cap và nút Cancel
Model có gradient masking	So sánh attack, random baseline và black-box attack
Kết luận từ dữ liệu quá nhỏ	Hiển thị số mẫu và khoảng tin cậy
Cache trả kết quả cũ	Cache key chứa model version, attack version và tham số

14. Definition of Done cho MVP

MVP được coi là hoàn thành khi:

1. Engineer đăng nhập và tạo được dataset.
2. Dataset được anonymize và chuyển sang trạng thái Ready.
3. Engineer chọn được một model detection hoặc segmentation.
4. Engineer chạy được common corruption, PGD và một loại patch.
5. Job Monitor hiển thị tiến trình.
6. Comparison Viewer hiển thị ảnh trước và sau.
7. Hệ thống tính được AP hoặc mIoU trước và sau.
8. Hệ thống tính được phần trăm suy giảm.
9. Robustness Matrix hiển thị được attack × severity.
10. Engineer gắn cờ được một case.
11. Reviewer xử lý được case và ghi quyết định.
12. Audit log được lưu.
13. Report được export.
14. Dataset chưa ẩn danh không thể dùng để chạy.
15. Banner Simulation Only xuất hiện trên mọi màn hình.
16. Không có kết nối tới production deployment.

PHẦN II — INFORMATION ARCHITECTURE

15. Cấu trúc điều hướng

15.1 Sidebar chính

```

AEGIS
|
├─ Dashboard
├─ Datasets
├─ Models
└─ Test Runs

```

- | | | — New Test Run
- | | | — Running Jobs
- | | | — Test Run History
- | — Reports
- | | | — Robustness Matrix
- | | | — Model Comparison
- | | | — Worst-Case Explorer
- | — Review Queue
- | — Settings

15.2 Header toàn cục

[Project selector] [GPU Budget] [Notifications] [User menu]

15.3 Banner toàn cục

SIMULATION ONLY

Kết quả chưa được validate cho triển khai thực tế.

PHẦN III — UI FLOW

16. Luồng tổng thể

flowchart TD

A[Đăng nhập] --> B{Vai trò}

B -->|Engineer| C[Dashboard Engineer]

B -->|Reviewer| D[Review Queue]

B -->|Admin| E[Administration]

C --> F[Datasets]

F --> G[Upload/Import Dataset]

G --> H[Validate Dataset]

H --> I[Anonymization]

I --> J{Anonymization đạt?}

J -->|Không| K[Needs Review]

K --> I

J -->|Có| L[Dataset Ready]

L --> M[New Test Run]

M --> N[Chọn Dataset và Model]

N --> O[Chọn Attack và Severity]

O --> P[Cấu hình GPU và Sampling]

P --> Q[Review Configuration]

```

Q --> R{Trong ngân sách?}

R -->|Không| P
R -->|Có| S[Submit Test Run]
S --> T[Job Monitor]
T --> U{Trạng thái}

U -->|Running| T
U -->|Failed| V[Retry/Inspect Error]
U -->|Cancelled| W[Test Run History]
U -->|Completed| X[Robustness Report]

X --> Y[Comparison Viewer]
X --> Z[Worst-Case Explorer]
X --> AA{Kết quả dưới ngưỡng?}

AA -->|Có| AB[Create Review Case]
AA -->|Không| AC[Close Test Run]

Y --> AD[Engineer Flag Case]
AD --> AB

AB --> D
D --> AE[Review Case Detail]
AE --> AF[Reviewer Decision]
AF --> AG[Audit Log]
AF --> AH{Yêu cầu chạy lại?}

AH -->|Có| M
AH -->|Không| AI[Case Closed]

```

17. Luồng Engineer

```

flowchart LR
    A[Dashboard] --> B[Datasets]
    B --> C[Anonymize]
    C --> D[New Test Run]
    D --> E[Estimate GPU]
    E --> F[Run]
    F --> G[Job Monitor]
    G --> H[Robustness Report]
    H --> I[Comparison Viewer]
    I --> J[Flag for Review]

```

18. Luồng Reviewer

```
flowchart LR
    A[Review Queue] --> B[Case Detail]
    B --> C[View Evidence]
    C --> D[View Report]
    D --> E[Choose Decision]
    E --> F[Add Required Note]
    F --> G[Submit Decision]
    G --> H[Audit Log]
```

19. Luồng tạo Test Run

```
flowchart LR
    A[Step 1 Dataset and Model]
    A --> B[Step 2 Attacks]
    A --> C[Step 3 Resources]
    A --> D[Step 4 Confirmation]
    A --> E[Submit]
```

Validation giữa các bước

Step 1

- Dataset phải Ready.
- Model phải có adapter hợp lệ.

Step 2

- Phải chọn ít nhất một attack.
- Tham số phải nằm trong giới hạn.

Step 3

- GPU cap phải lớn hơn 0.
- Sampling mode phải phù hợp dataset.

Step 4

- Ước tính không vượt hard cap.
- Người dùng xác nhận Simulation Only.

PHẦN IV — LOW-FIDELITY WIREFRAMES

20. Quy chuẩn bố cục chung

SIMULATION ONLY – Chưa validate cho triển khai thực tế		
Sidebar	Header: Project GPU Budget Notification User	
	Page Content	
		Dashboard
		Datasets
		Models
		Test Runs
		Reports
		Review Queue
Settings		

21. Màn hình 1 — Đăng nhập

Mục tiêu

Xác thực người dùng và điều hướng theo vai trò.

AEGIS

Adversarial Evaluation & Guard for Perception

Email

[_____]

Password

[_____]

[Đăng nhập]

_____ hoặc _____

[Đăng nhập bằng SSO]

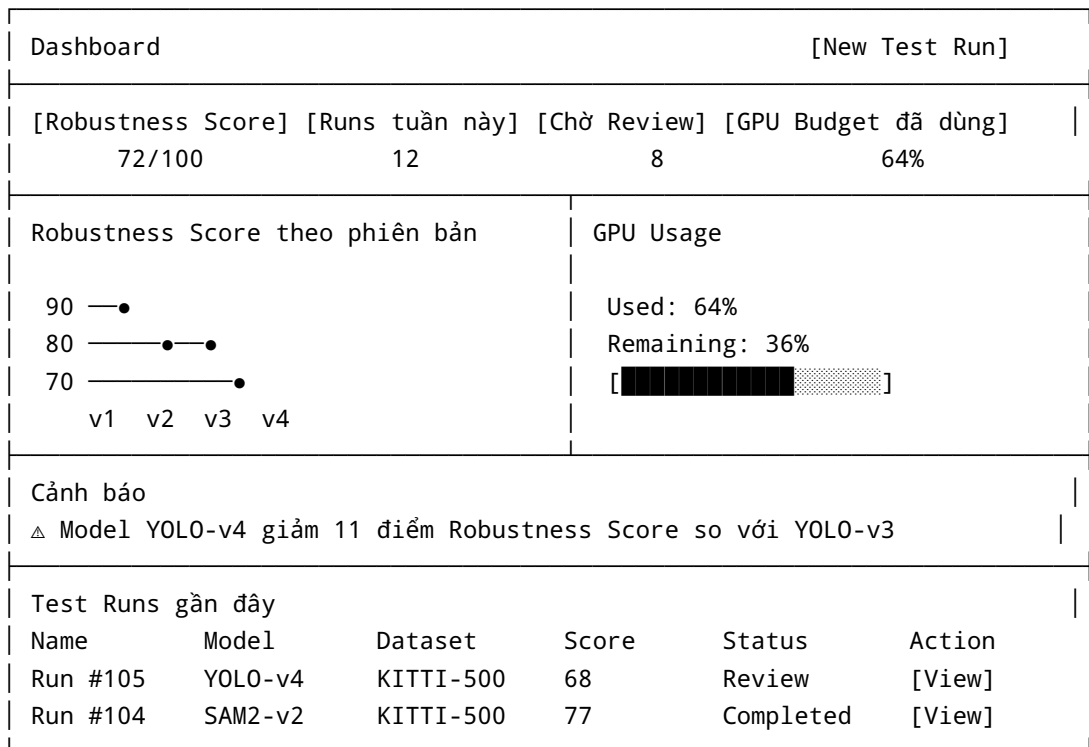
Trạng thái

- Sai tài khoản hoặc mật khẩu.
- Tài khoản bị khóa.
- SSO không phản hồi.
- Loading khi xác thực.

22. Màn hình 2 — Dashboard tổng quan

Mục tiêu

Cho người dùng thấy trạng thái robustness, tài nguyên và các cảnh báo chính.



Hành động chính

- Tạo Test Run.
- Mở report gần đây.
- Mở Review Queue.
- Xem cảnh báo model regression.

23. Màn hình 3 — Quản lý Dataset

Mục tiêu

Upload, kiểm tra và ẩn danh dữ liệu.

Datasets		[Upload]	[Import]	
Search [_____]		Status [All ▼]	Source [All ▼] Tags [▼]	
Dataset	Type	Samples	Privacy Status	Actions
KITTI-500	Images	500	Ready	[Open]
KITTI-Full	Images	7,481	Pending Anonymize	[Anonymize]
nuScenes-mini	Multi	404	Ready	[Open]
BDD100K-val	Images	10,000	Needs Review	[Review]
Privacy Gate				
Dataset chưa có Anonymization Manifest không thể sử dụng cho Test Run.				

Dataset Detail

KITTI-Full	Status: Anonymizing
Metadata 7,481 images 3 classes Source: KITTI Created by: Engineer A	Anonymization Progress 68% Faces found: 1,204 Plates found: 4,910 Failed images: 3
Preview	
Before Original image	After Face/plate blurred
[Previous] [Next]	[Approve Sample] [Reject]

24. Màn hình 4 — Model Registry

Mục tiêu

Quản lý model và checkpoint có thể đưa vào kiểm thử.

Model Registry					[Register Model]
Model	Version	Task	Adapter	Status	Action
YOLO11s	v1.3	Detection	YOLOAdapter	Ready	[Open]
SAM2-small	v2.1	Segmentation	SAMAdapter	Ready	[Open]
PointPillars	v1.0	3D Detection	MM3DAdapter	Testing	[Open]
Selected Model: YOLO11s v1.3					
Clean AP: 68.5					
Framework: PyTorch					
Checkpoint hash: a81...					
Last evaluated: 29/07/2026					
[View Test History] [Compare Versions]					

25. Màn hình 5 — New Test Run Wizard

Step 1 — Dataset và Model

New Test Run	Step 1 of 4
[1 Dataset & Model] – [2 Attacks] – [3 Resources] – [4 Confirm]	
Test Run Name	
[YOLO11s_KITTI_Robustness_01_____]	
Dataset	
[KITTI-500 – Ready ▼]	
500 images Car, Pedestrian, Cyclist Anonymized	
Model	
[YOLO11s v1.3 ▼]	
Detection Clean AP: 68.5 Adapter Ready	
[Cancel] [Continue]	

Step 2 — Attacks

New Test Run	Step 2 of 4
--------------	-------------

Select attack groups	
☒ A. Common Corruptions	
☒ Gaussian Noise	Severity [1 2 3 4 5]
☒ Motion Blur	Severity [1 2 3 4 5]
☒ Fog	Severity [1 2 3 4 5]
☐ B. Depth-aware Weather	
☒ C. Occlusion & Sensor Failure	
☒ Random Erasing	Severity [1 2 3 4 5]
☒ D. Adversarial Digital	
☒ PGD Epsilon [4/255 ▼]	Iterations [20 ▼]
☒ E. Adversarial Patch	
Patch size [10% ▼]	EOT [On]
☐ F. Black-box & Transfer	
☒ Auto Sweep selected attacks	
[Back] [Continue]	

Step 3 — Resources

New Test Run	Step 3 of 4
Sampling Mode	
☒ Full dataset ☐ Stratified subset ☐ Active Sampling	
Auto Red-Team Search	
☐ OFF	
GPU Budget Cap	
4.0 GPU-hours	
Advanced	
☒ Reuse clean predictions	
☒ Use content-addressed cache	
☒ FP16	
Current estimate	
500 images 21 configurations 10,500 variants	
Estimated GPU: 3.2 hours	
Estimated storage: 8.4 GB	

[Back] [Continue]


Step 4 — Confirm

New Test Run	Step 4 of 4
Configuration Summary	
Dataset: KITTI-500	
Model: YOLO11s v1.3	
Attacks: Gaussian Noise, Motion Blur, Fog, CutOut, PGD, Patch	
Severity: Auto Sweep	
Estimated GPU: 3.2 hours	
Budget Cap: 4.0 hours	
Privacy Check	
✓ Dataset anonymization manifest valid	
Safety Confirmation	
[✓] Tôi hiểu đây chỉ là kết quả mô phỏng, chưa phải chứng nhận triển khai thực tế.	
[Back] [Save Template] [Run Test]	

26. Màn hình 6 — Job Monitor

Mục tiêu

Theo dõi tiến trình, trạng thái và tài nguyên.

Test Run #105 – YOLO11s KITTI Robustness		Status: Running
Overall Progress		
[] 64%		
6,720 / 10,500 variants		
Current stage: Running Inference		
Estimated GPU used: 2.1 / 4.0 hours		
Pipeline	GPU Utilization	
✓ Prepare Dataset		

✓ Generate Corruptions ● Run Inference ○ Evaluate Metrics ○ Generate Report	100% 50% Memory: 13.2 / 16 GB
Real-time Logs 10:42 Batch 182 completed 10:43 PGD severity 3 completed 10:43 Cache hit rate 41%	
[Pause] [Cancel Run]	

Trạng thái lỗi

Attack generation failed

Method: PGD

Reason: CUDA out of memory

[Reduce batch size and retry]

[Skip failed configuration]

[Cancel Test Run]

27. Màn hình 7 — Comparison Viewer

Mục tiêu

Cho người dùng nhìn thấy chính xác model thất bại ở đâu.

Comparison Viewer	Run #105	Image 87/500	[Flag Review]
Attack: Fog Severity: 4 Degradation on image: 61%			
Before ← slider → After Green box: correct Red box: missed Yellow: confidence drop		Object Details Car #1 Clean conf: 0.91 Attack conf: 0.33 IoU: 0.78 → 0.51 Status: Confidence drop Pedestrian #2 Clean conf: 0.74 Attack: Missed Status: Failed	

Engineer note	
[Model misses pedestrian behind vehicle under heavy fog_____]	
[Previous] [Next] [Show Grad-CAM]	[Send to Review]

Bộ lọc

- Chỉ hiển thị object bị miss.
- Chỉ hiển thị sai class.
- Chỉ hiển thị giảm confidence.
- Lọc theo attack.
- Lọc theo severity.
- Lọc theo class.

28. Màn hình 8 — Robustness Report

Mục tiêu

Tổng hợp kết quả định lượng của Test Run.

Robustness Report – Run #105						[Export PDF] [CSV]	
Model: YOLO11s v1.3		Dataset: KITTI-500			Score: 68/100		
KPI							
AP Clean	mPC	rPC	ASR	GPU-hours			
68.5	42.7	62.3%	48.1%	3.1			
Robustness Matrix					Score by Category		
Attack	S1	S2	S3	S4	S5	Weather	54
Gaussian noise	4	8	15	26	41	Noise	71
Motion blur	3	9	18	32	49	Occlusion	66
Fog	6	14	29	47	68	Adversarial	52
CutOut	5	12	25	43	61		
PGD	18	31	49	66	79	[Radar chart]	
Robustness Accuracy by Severity							
100% —●							
75% —●							
50% —●—●							
25% —●							
S1 S2 S3 S4 S5							

Top findings

1. PGD severity 5 causes 79% degradation
2. Fog severity 5 causes frequent pedestrian misses
3. Model v1.3 is 8 points weaker than model v1.2 under occlusion

Tương tác drill-down

Click một ô heatmap:

PGD – Severity 4 – Degradation 66%

[Open 87 affected images]

[View Worst Cases]

[Create Review Case]

29. Màn hình 9 — Worst-Case Explorer

Mục tiêu

Xác định những biến thể làm model thất bại nghiêm trọng nhất.

Worst-Case Explorer		Sort by [Highest Degradation ▼]	
Filters: Attack [All] Class [All] Cluster [All] Model [YOLO11s v1.3]			
Rank #1	PGD $\epsilon=8/255$ T=20	Degradation: 91%	
Before	After	Pattern: Small pedestrian missed	
		Clean AP: 72	
		Attack AP: 6	
		[Open] [Send to Review]	
Rank #2	Fog $\beta=0.20$	Degradation: 84%	
Before	After	Pattern: Distant objects	
		Cluster size: 38	
		[Open Cluster] [Review]	
Auto Red-Team Progress			
Trials: 44/60 Best AP found: 5.8 GPU used: 1.7 hours			
[Convergence chart]			

Failure Cluster Detail

Cluster: Distant pedestrians under fog

38 cases

Average degradation: 72%

Common properties:

- Object distance > 35 m
- Bounding box height < 40 px
- Fog severity ≥ 4
- Partial occlusion present

[Export Cluster]

[Create Retraining Backlog]

[Send Representative Cases to Review]

30. Màn hình 10 — Review Queue

Mục tiêu

Cho Reviewer xem và đưa ra quyết định cuối cùng.

Review Queue		Pending: 8
Filter: Priority [All] Model [All] Decision [Pending] Source [All]		
Cases	Case Detail	
• Critical – Run #105 PGD degradation 91%	Case #R-205 Model: YOLO11s v1.3 Attack: PGD $\epsilon=8/255$ Degradation: 91%	
• High – Run #105 Fog pedestrian misses	[Before image] [After image]	
◦ Medium – Run #104 Mask IoU drop	Engineer note: "Small pedestrian consistently missed."	
	Decision	
	() Chấp nhận rủi ro	
	(●) Yêu cầu retrain	
	() Cần thêm dữ liệu	
	() Từ chối	
	Required note	
	[Add small-pedestrian fog data...]	

[Request Re-run] [Submit Decision]

Audit Log

30/07/2026 10:45

Reviewer Nguyễn A

Decision: Yêu cầu retrain

Note: Bổ sung dữ liệu pedestrian nhỏ trong sương mù severity 4-5.

30/07/2026 10:12

System

Case automatically created because Degradation > 80%.

31. Màn hình 11 — Settings và Administration

Màn hình này chỉ bắt buộc khi có vai trò Admin.

Settings & Administration

Tabs: [Users] [Models] [GPU Budget] [Review Thresholds] [Audit]

GPU Budget

Monthly limit: [500] GPU-hours

Warning threshold: [80]%

Hard cap per Test Run: [20] GPU-hours

Robustness Gate

Minimum Robustness Score: [70]

Maximum allowed regression: [5] points

ASR threshold: [40]%

[Save Changes]

PHẦN V — UI COMPONENTS

32. Thành phần giao diện dùng chung

32.1 Status badge

Trạng thái	Nhãn
Thành công	Ready, Completed, Approved
Đang xử lý	Uploading, Anonymizing, Running
Cảnh báo	Needs Review, Budget Warning
Lỗi	Failed, Rejected, Budget Exceeded
Trung tính	Draft, Queued, Cancelled

32.2 Metric card

Mỗi metric card cần có:

- Tên metric.
- Giá trị.
- Đơn vị.
- So sánh với baseline hoặc phiên bản trước.
- Tooltip định nghĩa.
- Trạng thái tốt/cảnh báo/xấu.

32.3 Attack selector

- Nhóm attack dạng accordion.
- Checkbox từng method.
- Severity selector.
- Cost class.
- Ước tính số biến thể.
- Tooltip giải thích.

32.4 Empty state

Ví dụ tại Dashboard:

Chưa có Test Run nào.

Tạo Test Run đầu tiên để bắt đầu đánh giá độ bền vững của model.

[Create Test Run]

32.5 Error state

Thông báo lỗi phải trả lời ba câu hỏi:

1. Điều gì đã xảy ra?
2. Nguyên nhân có thể là gì?
3. Người dùng có thể làm gì tiếp theo?

PHẦN VI — UX RULES

33. Quy tắc trải nghiệm

33.1 Không sử dụng màu làm tín hiệu duy nhất

Ngoài màu đỏ, vàng, xanh, phải có icon hoặc text:

- Correct.
- Confidence Drop.
- Missed.
- Misclassified.

33.2 Số liệu phải có ngữ cảnh

Không hiển thị riêng:

Robustness Score: 68

Phải hiển thị:

Robustness Score: 68/100
Giảm 8 điểm so với model version trước.
Yếu nhất ở nhóm Adversarial Digital.

33.3 Cảnh báo chi phí trước hành động

Trước khi người dùng bấm Run:

Cấu hình này dự kiến sử dụng 3.2 GPU-hours.
Ngân sách còn lại của project là 4.6 GPU-hours.

33.4 Xác nhận khi hủy job

Hủy Test Run?

Kết quả đã hoàn thành sẽ được lưu.
Các batch đang chạy có thể bị dừng.

[Keep Running] [Cancel Test Run]

33.5 Quyết định Review không thể bỏ trống

Reviewer phải chọn quyết định và nhập ghi chú trước khi Submit.

PHẦN VII — RESPONSIVE BEHAVIOR

34. Desktop

Là giao diện chính, tối ưu cho màn hình từ 1366 px trở lên.

- Sidebar cố định.
- Comparison Viewer chia hai cột.
- Robustness Matrix hiển thị đầy đủ.
- Review Queue theo master-detail.

35. Tablet

- Sidebar thu gọn.
- Các panel chuyển thành tab.
- Comparison Viewer ưu tiên ảnh, panel metric mở dạng drawer.

36. Mobile

Chỉ hỗ trợ các thao tác giám sát cơ bản:

- Xem Dashboard.
- Xem trạng thái job.
- Nhận thông báo.
- Xem Review Queue.
- Ghi quyết định đơn giản.

Không ưu tiên:

- Tạo cấu hình attack phức tạp.
- So sánh ảnh độ phân giải cao.
- Phân tích Robustness Matrix lớn.

PHẦN VIII — KỊCH BẢN DEMO

37. Demo 5 phút

Bước 1 — Dashboard

Hiển thị:

- Robustness Score.
- Model regression alert.
- GPU budget.
- Số case đang chờ review.

Bước 2 — Tạo Test Run

Chọn:

- Dataset KITTI-500.
- Model YOLO11s.
- Gaussian Noise.
- Fog.
- PGD.
- Adversarial Patch.

Cho người xem thấy ước tính GPU trước khi chạy.

Bước 3 — Job Monitor

Chạy một tập nhỏ để hiển thị:

- Tiến trình.
- GPU utilization.
- Log real-time.

Bước 4 — Comparison Viewer

Mở một ảnh mà model bỏ sót Pedestrian sau khi áp dụng fog hoặc PGD.

Bước 5 — Robustness Report

Mở report đã chạy sẵn trên tập lớn:

- Heatmap.
- Robustness Score.
- Attack Success Rate.
- Worst-Case Top-N.

Bước 6 — Auto Red-Team

Cho thấy thuật toán tự tìm ra tham số gây suy giảm mạnh nhất với số trial giới hạn.

Bước 7 — Review Queue

Reviewer chọn:

Yêu cầu retrain

Và ghi chú:

Bổ sung dữ liệu pedestrian kích thước nhỏ trong điều kiện sương mù severity 4–5.

Kết thúc bằng Audit Log và banner Simulation Only.

PHẦN IX — ĐỀ XUẤT CHIA CÔNG VIỆC

38. Phân chia cho nhóm bốn người

Thành viên	Phạm vi
Người 1 — Frontend/UI	Dashboard, New Test Run, Job Monitor, Comparison Viewer
Người 2 — Attack Engine	Common corruption, CutOut, PGD, patch
Người 3 — Model & Evaluation	ModelAdapter, inference, AP, IoU, Degradation, ASR
Người 4 — Backend & Review	FastAPI, database, queue, report, RBAC, Review Queue

Phần dùng chung

Cả nhóm thống nhất trước:

- Schema Test Run.
- Schema attack plugin.
- Schema prediction.
- Schema metric result.
- API contract.
- Dataset ID và model version.
- Quy tắc trạng thái job.
- Quy tắc Simulation Only.
- Definition of Done.

PHẦN X — API GỢI Ý CHO MVP

39. API chính

```
POST /auth/login
GET /users/me
```

```

POST    /datasets
GET     /datasets
GET     /datasets/{dataset_id}
POST    /datasets/{dataset_id}/anonymize
GET     /datasets/{dataset_id}/anonymization

GET     /models
POST    /models
GET     /models/{model_id}

GET     /attacks
GET     /attacks/{attack_id}

POST    /test-runs/estimate
POST    /test-runs
GET     /test-runs
GET     /test-runs/{run_id}
POST    /test-runs/{run_id}/cancel
GET     /test-runs/{run_id}/progress

GET     /test-runs/{run_id}/report
GET     /test-runs/{run_id}/comparison
GET     /test-runs/{run_id}/worst-cases

POST    /review-cases
GET     /review-cases
GET     /review-cases/{case_id}
POST    /review-cases/{case_id}/decisions

GET     /audit-logs
POST    /exports

```

WebSocket

```
WS /test-runs/{run_id}/events
```

Sự kiện đề xuất:

```

run.queued
run.started
stage.started
stage.completed
batch.completed
metric.updated
budget.warning
run.failed

```

```
run.cancelled  
run.completed
```

PHẦN XI — RELEASE PLAN

40. Giai đoạn 1 — MVP

- Authentication và RBAC.
- Dataset import.
- Anonymization preview.
- YOLO hoặc SAM2 adapter.
- Common corruption.
- PGD.
- Một patch.
- Test Run.
- Job Monitor.
- Comparison Viewer.
- AP hoặc IoU.
- Robustness Matrix.
- Review Queue.
- CSV/PDF export cơ bản.

41. Giai đoạn 2 — Benchmark và tối ưu

- Severity Sweep.
- Benchmark nhiều model.
- Robustness Accuracy.
- ASR.
- Robustness Score.
- Cache.
- Dynamic batching.
- Active Sampling.
- W&B.
- GPU cost report.

42. Giai đoạn 3 — Auto Red-Team

- Bayesian Optimization hoặc Optuna.
- Worst-Case Explorer.
- Failure clustering.
- Grad-CAM.
- CI/CD Gate.

43. Giai đoạn 4 — Multi-sensor

- LiDAR corruption.
- PointPillars.

- BEVFusion.
- Transfer attack.
- Scenario replay.
- Digital Twin integration.