

● PROJECT P-195 · AI IN ACTION

AdverTest

Nền tảng kiểm thử adversarial cho Perception Models.
Phát hiện điểm yếu trước khi triển khai thực tế.

Robustness Testing

Adversarial ML

Perception Safety

Human-in-the-loop

Perception models dễ bị đánh lừa

Nhiều nhỏ vô hình, thời tiết xấu hay patch adversarial có thể đánh sập hoàn toàn hệ thống nhận diện — gây rủi ro an toàn nghiêm trọng cho xe tự hành & robotics.

-48%


AP giảm dưới tấn công **FGSM** (White-box, $\epsilon = 8$)

-40%

AP giảm dưới **Sương mù** (Physical, Severity 5)

-53%

AP giảm dưới **DPatch** (Physical, Occlusion)



AdverTest: **End-to-end** robustness testing

Hệ thống tự động sinh nhiễu song song trên GPU, đánh giá mô hình và cung cấp vòng phản hồi khép kín (Closed-loop feedback).

- **Performance:** Xử lý & sinh nhiễu song song Multi-GPU (<50ms/ảnh).
- **Closed-loop Retraining:** Tự động xuất Adversarial Dataset để train lại mô hình phòng thủ.

1. Import & Anonymize

Hỗ trợ format KITTI, nuScenes. Tự động ẩn danh khuôn mặt (GDPR compliance).

2. Parallel Generation

Áp dụng 6 nhóm tấn công × 5 severity tạo ra bộ test bao phủ toàn diện 95+ biến thể.

3. Benchmark Engine


Tính toán 12 metrics: AP, mAP, IoU, ASR, và RobustScore. Xuất báo cáo Heatmap.

4. Review & Retrain

Giao diện duyệt kết quả (Human-in-the-loop) để ra quyết định Accept/Retrain.

Phân loại tấn công

6 nhóm, 5 mức độ nghiêm trọng (Severity) — mô phỏng sát nhất các rủi ro vận hành thực tế.



NHÓM A: CORRUPTION

19 loại nhiễu tín hiệu (Gaussian, Defocus blur...).

19 × 5 severity.

NHÓM D: WHITE-BOX

Tấn công gradient (FGSM, PGD).
Thao túng trực tiếp pixel để lừa model.

NHÓM B: WEATHER

Mô phỏng thời tiết vật lý: sương mù (Koschmieder), mưa bão, tuyết.

NHÓM E: PATCH

Tấn công vật lý bằng Patch in ấn (DPatch). Đánh lừa bằng vùng che khuất.

NHÓM C: OCCLUSION

Che khuất ngẫu nhiên hoặc có chủ đích (10-90% diện tích vật thể).

NHÓM F: SENSOR FAULTS

Mô phỏng lỗi phần cứng cảm biến: Dead pixels, row/column line drop.

Heatmap & Metrics

Trực quan hóa độ suy giảm hiệu năng. ROI: Giảm 80% thời gian phân tích thủ công.

85.4

AP CLEAN

47.2

ROBUSTSCORE

32.1%

ASR

5 SANITY CHECKS (AUTO-QA)

- ✓ $\epsilon=0 \rightarrow AP \approx AP_{\text{clean}}$ (sai số < 0.1)
- ✓ $AP(c,s)$ giảm đơn điệu theo severity (s)
- ✓ Tác động nhiễu ngẫu nhiên $\leq$ adversarial
- ✓ Tính tất định: ± 0.5 AP giữa 2 lần chạy

	S=1	S=2	S=3	S=4	S=5
FGSM	-2.1	-8.4	-21.3	-35.7	-48.9
PGD	-3.5	-12.1	-28.6	-42.3	-56.1
Gaussian	-1.2	-4.5	-11.8	-22.4	-31.6
Fog	-0.8	-3.2	-9.7	-18.5	-27.3
DPatch	-5.3	-15.7	-31.2	-44.6	-52.8

Real-time Analytics UI

Giao diện Web Dashboard gồm 6 màn hình chức năng, được thiết kế chuẩn mực B2B cho kỹ sư AI.

Datasets

Quản lý dữ liệu lớn.

Test Pipeline

Trigger test & dự toán.

Job Monitor

Theo dõi tiến độ realtime.

Comparison

So sánh Clean vs Attacked.



Model-Agnostic Architecture

Thiết kế **Plug-and-play**: Hỗ trợ đánh giá bất kỳ mô hình độc quyền nào thông qua Adapter Pattern, không giới hạn ở YOLO hay SAM.

Frontend & API Server

Giao tiếp RESTful / WebSockets (Next.js, FastAPI).

Detection Adapter (YOLO11)


Giao diện chuẩn hóa nhãn và bounding box mapping.

Segmentation Adapter (SAM2)

Xử lý prompt encoding và đánh giá mask IoU.

Core Engine (Person D)

Điều phối pipeline sinh nhiễu và benchmark phân tán.



Production-ready Pipeline

Hệ thống áp dụng các tiêu chuẩn phát triển phần mềm khắt khe nhất,
bảo đảm độ tin cậy tuyệt đối trước khi release.

98%

Test Coverage

881+ Unit & Integration Tests tự động hóa hoàn toàn.

0

Vulnerabilities

Ruff (Python) & ESLint (JS). Pass 100% Security Scan.

CI/CD

Automated Delivery

Mỗi commit đều được check chất lượng trước khi merge.

SOC 2

Compliance Ready

Kiểm soát truy cập (RBAC), Audit Logging và Ẩn danh data.

Core Technologies

Xây dựng nền tảng Robustness Testing Model-Agnostic với hiệu năng vượt trội.

Backend & Platform

- ⚡ **FastAPI & Uvicorn**
- 🗄️ **SQLAlchemy & SQLite**
- ⚙️ **Celery & Redis**

AI / Vision Models

- 🔥 **PyTorch** (Core GPU)
- 👁️ **Ultralytics** (YOLO11)
- 🧩 **MMDet3D / SAM2**
- 🛡️ **Torchattacks & Kornia**

Tracking & Metrics

- 📊 **Weights & Biases (W&B)**
- 🎯 **Optuna** (Auto Search)
- 📊 **PyCOCOTools**

Tiến Độ & Hiệu Suất Thực Tế

Các chỉ số đo lường trực tiếp từ Source Code dự án.

100%

Core Engine & Protocol

Hoàn thành toàn bộ (12/12 Module) của Core CPU, Dataset Generator, Defense Manifest. Đã pass Unit Tests.

6 Nhóm

Adversarial Attacks

Hỗ trợ toàn diện từ Digital (FGSM/PGD), Weather (Sương/Mưa) đến Physical Patch. Sẵn sàng tích hợp YOLO11 & SAM2.

< 50ms

Latency Inference Target

Kiến trúc GPU Red-teaming được thiết kế tối ưu hóa, đảm bảo sinh nhiễu và infer với tốc độ thời gian thực.

15+

REST Endpoints Chuẩn SOC 2

Hoàn thành Backend API, RBAC, Audit Logging. Tích hợp W&B API Key Encryption bằng thuật toán AES Fernet.

Quy Mô & Ứng Dụng

Nhu cầu về AI Robustness Testing là nền tảng cho kỷ nguyên Agentic AI.



Autonomous Vehicles (Xe tự hành)

Đánh giá độ an toàn của hệ thống cảm biến (LiDAR, Camera) trước các điều kiện thời tiết xấu và các cuộc tấn công vật lý (sticker lừa đảo).



Defense & Security (An ninh - Quốc phòng)

Đảm bảo hệ thống AI nhận diện mục tiêu ổn định, chống lại các kỹ thuật spoofing và adversarial attacks (tàng hình AI) trong môi trường tác chiến.



Healthcare & Robotics

Robot y tế và trợ lý AI đòi hỏi độ tin cậy tuyệt đối. Bất kỳ sai lệch nhỏ nào trong Perception Model đều có thể dẫn đến hậu quả nghiêm trọng.

VINAI • AI IN ACTION

AdverTest

Làm chủ sự an toàn.
Bức phá sức mạnh của AI.

- **Next Steps** Triển khai & Đánh giá trên nền tảng Robotics thực tế

Thank you for listening!